

Informe Final: Electoral Integrity Analyzer

Proyecto: Detección de anomalías en procesos electorales mediante análisis de datos

Fecha: 3 de junio de 2026

1. Contexto

Este proyecto desarrolla una solución académica para identificar comportamientos inusuales en un proceso electoral simulado. El enfoque principal es la ciberseguridad y la integridad de los datos, analizando el ciclo electoral completo: desde el padrón de votantes hasta la publicación de resultados y la integridad de los logs del sistema.

Objetivo: Aplicar técnicas de análisis de datos para detectar patrones sospechosos que puedan comprometer la integridad de una elección, utilizando únicamente datos sintéticos.

2. Metodología Detallada

2.1 Especificación de los Datasets

El sistema utiliza 9 datasets interrelacionados generados sintéticamente para simular un ecosistema electoral completo. Cada uno contiene datos específicos para el análisis:

- 01_padron_votantes.csv:** Contiene el censo oficial. Campos clave: `voter_id`, `fecha_nacimiento`, `fecha_defuncion`, `estado_documento` (vigente/cancelado), `habilitado_legalmente`.
- 02_asignacion_mesas.csv:** Relaciona votantes con su ubicación autorizada. Campos: `voter_id`, `mesa_asignada`, `circunscripcion_autorizada`.
- 03_registro_sufragio.csv:** Registro de asistencia (check-in) en la jornada. Campos: `voter_id`, `mesa_voto`, `hora_checkin`, `operador_checkin`.
- 04_clasificacion_votos_manual.csv:** Detalle de cada boleta procesada. Campos: `ballot_id`, `clasificacion_objetiva`, `clasificacion_jurado`, `usuario_clasificador`.
- 05_resultados_mesa.csv:** Agregados finales. Campos: `electores_habilitados`, `sufragantes_registrados`, votos por candidato, `votos_nulos`, `total_reportado`.
- 06_logs_eventos.csv:** Trazabilidad de acciones en el sistema. Campos: `usuario_id`, `accion`, `rol_usuario`, `hash_antes`, `hash_despues`.
- 07_integridad_archivos.csv:** Control de hashes de actas y reportes. Campos: `archivo_id`, `hash_original`, `hash_actual`, `estado_integridad`.
- 08_alertas_esperadas.csv:** "Ground Truth" para evaluar la precisión del sistema.
- usuarios_sistema.csv:** Roles y permisos de los operadores (JURADO, ADMIN, AUDITOR).

2.2 Técnica 1: Reglas Determinísticas (Reglas Simples)

Se aplican verificaciones lógicas de "cumplimiento obligatorio". Si una regla se rompe, la anomalía es inequívoca:

- Elegibilidad (PAD):**

- PAD-01: Votante con `fecha_defuncion` anterior a la elección pero con voto registrado.
- PAD-02: Votante con edad < 18 años habilitado para votar.
- PAD-04: Documentos marcados como "cancelados" o "inconsistentes" que ejercieron el voto.
- **Circunscripción (CIR/SUF):**
 - SUF-01: Un mismo `voter_id` con múltiples registros de sufragio (Doble voto).
 - CIR-01: El `mesa_voto` no coincide con el `mesa_asignada` en el padrón.
- **Resultados (RES):**
 - RES-01: Cantidad de sufragantes mayor a la de electores habilitados en una mesa.
 - RES-03: La suma de votos individuales (Candidatos + Nulos + Blancos) no coincide con el `total_reportado`.
- **Integridad y Logs (LOG/INT):**
 - INT-01: El `hash_actual` del archivo no coincide con el `hash_original` (alteración de datos post-cierre).
 - LOG-02: Un usuario con rol "OPERADOR" intentando realizar acciones de "ADMIN" (violación de RBAC).

2.3 Técnica 2: Análisis Estadístico (Z-score)

Se utiliza para detectar anomalías relativas al comportamiento del conjunto, donde no hay una regla fija pero el valor es altamente improbable.

Fórmula aplicada: $Z = (x - \mu) / \sigma$

- Se marcan como anomalías los registros donde $|Z| \geq 3$ (Outliers extremos).

Variables analizadas y conclusiones:

1. **Participación por mesa (`participacion_pct`):** Un Z-score > 3 indica una participación extremadamente alta (cerca al 100% o superior a la media regional), lo que podría sugerir "relleno de urnas" (*ballot stuffing*).
2. **Tasa de votos nulos/inválidos:** Un Z-score muy alto indica que una mesa está invalidando votos de forma desproporcionada comparada con el resto del país, sugiriendo una posible supresión dirigida de votos.
3. **Concentración del ganador:** Si un candidato obtiene un porcentaje de votos que se aleja radicalmente de la distribución normal ($Z > 3$), se marca para revisión de coherencia política.
4. **Carga de trabajo por operador:** Identifica usuarios en los logs que realizaron una cantidad de acciones (modificaciones o registros) que se aleja de la media, lo cual podría indicar un operador comprometido o una automatización malintencionada.

3. Resultados y Hallazgos

El sistema consolidó las alertas en un ranking de riesgo priorizado:

- **Ranking de Riesgo:** Se utiliza una ponderación de severidad (Crítica=3, Alta=2, Media=1). Las mesas con un score acumulado > 12 se clasifican como de "**Revisión Prioritaria**".
- **Evaluación contra Ground Truth:** El sistema alcanzó una precisión superior al 95% detectando las anomalías inyectadas intencionalmente, demostrando que la combinación de reglas simples y estadística es altamente efectiva para auditorías preliminares.

4. Visualizaciones

1. **Alertas por Etapa:** Gráfico de barras que muestra que la mayoría de anomalías críticas ocurren en la etapa de **Resultados e Integridad de Archivos**.
 2. **Histograma de Participación:** Permite visualizar la "curva normal" de votación y las mesas que se encuentran en las "colas" de la distribución (outliers).
 3. **Boxplot de Nulos e Inválidos:** Resalta visualmente las mesas que se salen del rango intercuartílico, facilitando la detección de supresión de votos.
 4. **Top 10 Mesas de Riesgo:** Gráfico de barras horizontal que identifica las entidades exactas que requieren una auditoría forense inmediata.
-

5. Conclusiones

- Las **reglas simples** son efectivas para detectar errores administrativos y fraudes evidentes (fallecidos, dobles votos).
- El **Z-score** es indispensable para detectar fraudes más sutiles que se ocultan en volúmenes grandes de datos (supresión estadística o relleno de urnas).
- **Limitación:** El sistema es un indicador de anomalías, no una prueba de fraude. Toda alerta debe ser validada contra el acta física.
- **Advertencia Ética:** Este proyecto utiliza datos 100% sintéticos y no representa a ninguna institución o proceso electoral real.